

01 每页字数不要太多



常见问题： 满屏文字，没有图示。概念可能说不清，听众记不住

反面展示样例

任务定义

● 机器翻译 (Machine Translation, MT)

机器翻译是自然语言处理领域中最经典、最具挑战性且应用最广泛的任务之一。其核心目标是将一种自然语言（源语言）的文本自动转换为另一种自然语言（目标语言）的文本，同时最大程度地保留原文的语义、语气和风格。

具体来说，给定一段源语言文本，机器翻译系统需要理解其词汇、语法、语义及上下文信息，跨越语言之间的差异，包括词序、语法结构、成分省略和修辞表达等，并结合目标语言的语言规范与表达习惯，生成流畅、准确、自然的目标语言文本。

机器翻译的难点主要体现在两个方面。一方面，不同语言在词汇、句法结构、语义表达和文化背景上存在显著差异。另一方面，翻译过程还需要处理多义词、成语、俚语、专有名词、长难句、指代消解和逻辑关系等复杂现象，并在忠实原文和符合目标语言表达习惯之间取得平衡。此外，领域差异和语言风格也会显著影响翻译质量。

随着深度学习和大规模预训练模型的发展，神经机器翻译（NMT）已成为主流方法。端到端学习显著提升了翻译的流畅度和准确性，但长文本一致性、低资源语言、专业领域术语翻译以及文化适配等方面仍面临诸多挑战。机器翻译已广泛应用于跨语言沟通、文档翻译、跨境电商、国际合作和信息获取等场景，是连接不同语言与文化的重要技术基础。

● 图像描述生成 (Image Captioning)

图像描述生成是计算机视觉与自然语言处理交叉融合的一项典型任务。其核心目标是根据输入图像的视觉内容，自动生成一段能够准确、全面且通顺地描述图像关键信息的自然语言文本。


具体来说，给定一张图像，模型需要识别图像中的物体及其属性，理解人物及其动作、场景类型、位置关系、空间布局以及图像中的事件或活动，并将这些视觉信息组织成符合语法规则、逻辑清晰、表达自然的句子或段落。

图像描述生成的难点在于，图像中的信息通常丰富且具有多层次特征。模型既需要关注关键区域，也要避免遗漏重要内容或生成过多冗余信息。此外，同一幅图像可能存在多种合理的描述方式，复杂场景中的多物体交互、遮挡、光照变化和视角差异也会带来识别与理解方面的挑战。

主流方法通常使用卷积神经网络或视觉Transformer提取图像特征，再结合循环神经网络或Transformer解码器生成文本。图像描述生成在辅助视觉理解、视障人士支持、图像检索、自动文案生成、内容审核、人机交互、教育和娱乐等领域具有广泛应用前景，也是图文对话和视觉问答等高级视觉语言任务的重要基础。

推荐展示样例

任务定义



减少文字，增加图片， "扫一眼就懂"，一图胜千言。

02 一页只承担一个核心任务



常见问题：一页同时讲问题、方法、实验和结论，信息混杂，主线不清



反面展示样例

高效推理

Method	GSM8K			MATH-500			AMC23			AIME24			AIME25			AVG.	
	Acc↑	Tok	ReL↓	Acc↑	Tok	ReL↓	Acc↑	Tok	ReL↓	Acc↑	Tok	ReL↓	Acc↑	Tok	ReL↓	Acc↑	ReL↓
Qwen2.5-1.5B 系列																	
Ours (Base)	80.1	2086	76.2	78.8	3958	139.4	62.5	6392	242.9	20.0	13765	536.8	16.7	12684	504.7	51.5	300.0
+H2O	76.1	2116	71.7	75.4	3835	128.5	55.0	6230	209.7	13.3	13921	462.2	10.0	12802	428.6	46.0	260.1
+SepLLM	77.3	2230	75.8	76.0	3890	130.3	57.5	6573	220.2	13.3	13690	452.6	13.3	12690	423.9	47.5	260.6
LightThinker	78.8	2109	69.6	77.6	4060	134.8	60.5	6312	214.6	16.7	13827	461.6	13.3	12934	434.6	50.1	263.0
INFYTHINK	79.5	2503	89.3	78.0	4750	170.2	62.5	7605	263.5	16.7	16318	566.2	16.7	15020	501.0	50.7	318.0
Ours (Full)	82.1	2116	69.7	81.2	3812	125.8	67.5	6460	213.2	26.7	13610	440.1	23.3	12910	416.0	56.2	253.0
Qwen2.5-7B 系列																	
Ours (Base)	89.4	2649	96.4	87.4	4253	161.6	82.5	6704	242.9	40.0	12901	522.1	30.0	13204	548.1	65.9	314.2
+H2O	83.5	2730	92.0	82.6	4389	147.1	77.5	6843	209.7	30.0	13274	448.9	23.3	13204	443.7	59.4	268.3
+SepLLM	84.9	2582	92.3	84.2	4244	144.3	80.0	6511	220.2	33.3	13100	484.7	23.3	12972	435.9	61.1	275.5
LightThinker	85.6	2779	90.0	84.8	4321	145.2	80.0	6790	214.6	33.3	13307	449.0	26.7	13250	443.9	62.1	268.5
INFYTHINK	87.9	3237	117.0	86.2	5050	184.8	82.5	8061	254.3	36.7	15094	508.7	30.0	15448	530.5	64.7	319.0
Ours (Full)	90.9	2603	87.2	90.0	4196	140.6	85.0	6665	213.2	43.3	13017	434.8	33.3	13191	440.6	68.3	263.3

注：Acc↑ 表示 Accuracy 越高越好，ReL↓ 表示相对长度（越低越好），Tok 表示生成 Token 数（越低越好）。

问题总结

- 长链推理导致 Token 激增，推理延迟高；
- 某些基线方法在高难度数据集（AIME）性能明显下滑；
- 不同模型规模、数据集之间存在较大波动。

方法要点

- 筛选：基于规则+模型置信度过滤低质量路径；
- 压缩：合并冗余步骤，减少无效 Token；
- 投票：多路径多数投票，提升一致性；
- 奖励模型：重排序候选解，优先高质量输出。

实验结论（简要）

- 相比基线，Ours (Full) 在大多数数据集上取得最高的准确率；
- 同时显著降低相对长度（ReL），控制了推理成本；
- 在 7B 模型上收益更明显，但增益并非在所有设置下完全一致。

问题

- 长链推理成本高，推理 Token 急剧增长；
- 鲁棒性不足，在复杂数学推理任务上表现不稳定；
- 泛化有限，不同难度和题型下差异明显。

方法

- 引入筛选（过滤低质量路径）；
- 结构化压缩（减少冗余 Token）；
- 多路径投票（提升一致性）；
- 奖励模型重排序（偏好高质量解）。

实验设置

- 模型：Qwen2.5-1.5B / Qwen2.5-7B
- 数据集：GSM8K, MATH-500, AMC23, AIME24, AIME25
- 评测指标：Accuracy(↑), Token(↓), Rel. Length(↓)
- 评测方式：单次采样，温度=0.7，最大生成长度=32768
- 硬件：8×A100 80GB

进一步分析（待做）

- 不同过滤阈值对性能与成本的影响；
- 奖励模型替换与消融实验；
- 泛化到更多数据集与跨模型验证；
- 长链推理可解释性与错误分析。



推荐展示样例

高效推理

01 问题是什么

长链推理带来更高计算开销，但性能收益并不稳定



推理成本高

长链推理使生成 Token 数快速增长，直接带来更高的推理延迟与计算成本。



鲁棒性不足


在 AIME 等复杂数学任务上，部分基线方法表现波动，链更长并不等价于答案更可靠。



泛化收益不一致

不同模型规模、不同数据集之间存在明显差异，单一压缩策略难以稳定适配所有场景。

推理长度与有效收益的典型关系



目标：在保持或提升准确率的同时，减少冗余推理，并让高难任务的收益更稳定。

问题来自原母版中的三类现象：Token 成本、复杂任务稳定性、跨模型 / 数据集泛化差异。



每页只回答一个问题，例如“问题是什么”“方法怎么解决”“实验说明什么”“结论是什么”。

03 标题要有意义



常见问题：标题只写“实验”“结果”“讨论”，看完可能仍不知道本页讲什么



反面展示样例

实验

	Metrics	Mistral-7B	LLaMA-2-7B	GPT-4	Mistral-Interact
模糊性判断					
正确率	Vagueness Judgement Accuracy (%)	49.07	79.63	82.41	85.19
缺失细节的恢复率	Missing Details Recover Rate (of Importance Level, %) - Lv 3	68.42	60.98	75.22	72.28
	- Lv 2	56.94	38.76	63.14	67.08
	- Lv 1	23.08	28.92	37.50	27.94
总结的意图准确率	Summary Intention Coverage Rate (%)	91.43	61.87	100.00	96.37
	Options Presenting Rate (%)	42.46	47.64	40.31	84.08
	Options Reasonable Rate (%)	100.00	81.79	100.00	98.70
	Average Provided Options	1.46	1.35	1.21	2.72
	Average Inquired Missing Details	3.91	5.80	4.78	4.52
	Average Conversation Rounds	1.62	3.02	2.69	4.15
	Average Inquired Missing Details Per Round	2.80	2.49	2.31	1.26

- 1 Mistral-Interact 能够最准确地判断任务模糊性。
- 2 Mistral-Interact 能够恢复超过70%的最重要的缺失细节，远远优于其他开源模型。
- 3 Mistral-Interact 能够根据用户意图做出准确的总结，远远优于其他开源模型。



推荐展示样例

实验—指令理解能力的提升

	Metrics	Mistral-7B	LLaMA-2-7B	GPT-4	Mistral-Interact
模糊性判断					
正确率	Vagueness Judgement Accuracy (%)	49.07	79.63	82.41	85.19
缺失细节的恢复率	Missing Details Recover Rate (of Importance Level, %) - Lv 3	68.42	60.98	75.22	72.28
	- Lv 2	56.94	38.76	63.14	67.08
	- Lv 1	23.08	28.92	37.50	27.94
总结的意图准确率	Summary Intention Coverage Rate (%)	91.43	61.87	100.00	96.37
	Options Presenting Rate (%)	42.46	47.64	40.31	84.08
	Options Reasonable Rate (%)	100.00	81.79	100.00	98.70
	Average Provided Options	1.46	1.35	1.21	2.72
	Average Inquired Missing Details	3.91	5.80	4.78	4.52
	Average Conversation Rounds	1.62	3.02	2.69	4.15
	Average Inquired Missing Details Per Round	2.80	2.49	2.31	1.26

- 1 Mistral-Interact 能够最准确地判断任务模糊性。
- 2 Mistral-Interact 能够恢复超过70%的最重要的缺失细节，远远优于其他开源模型。
- 3 Mistral-Interact 能够根据用户意图做出准确的总结，远远优于其他开源模型。



用一句话概括本页内容或结论，例如“有关评估指令理解能力的讨论”。

04 颜色不要太多太乱



常见问题：PPT中使用的颜色过多，观众可能会视觉疲劳



反面展示样例

背景

大型视觉语言模型中上下文学习的挑战

1. 跨模态交互的复杂性



模型在**浅层**收集和理解信息
模型在**深层**进行**视觉和语言信息**的交互

⚠ 上下文丢失、注意力分散

2. 不同模态表征空间的差异

视觉特征和LLM嵌入**处于不同的空间**

⚠ 跨模态信息存在**间隙**



推荐展示样例

背景

大型视觉语言模型中上下文学习的挑战

1. 跨模态交互的复杂性



模型在**浅层**收集和理解信息
模型在**深层**进行**视觉和语言信息**的交互

上下文丢失、注意力分散

2. 不同模态表征空间的差异

视觉特征和LLM嵌入**处于不同的空间**

跨模态信息存在**间隙**



在PPT中针对重点适当标红、标蓝、加粗，不要让颜色太多太乱

05 注意排版细节

常见问题：元素没有对齐，字号层级混乱

反面展示样例

背景

大型视觉语言模型 (LVLMs)

结合图像和文字信息，以便模型理解和完成跨模态任务。

图像文本问答

图像文本匹配

图像描述生成

文本生成图像

文本

图中最大的动物是什么？

图片



狮子


上下文学习 (ICL)

模型查看少量示例，根据示例学习如何处理新的问题。



推荐展示样例

背景



大型视觉语言模型 (LVLMs)

结合图像和文字信息，以便模型理解和完成跨模态任务。



上下文学习 (ICL)

模型查看少量示例，根据示例学习如何处理新的问题。

跨模态任务

图像文本问答

图像文本匹配

图像描述生成

文本生成图像

文本

图中最大的动物是什么？

图片



少量示例指导



文本

最大的动物是狮子。

图片



好的排版不是装饰，而是让观众更快理解内容：对齐、统一、留白、分层。

06 用案例引出问题，而不是先讲抽象定义



常见问题：一上来堆任务定义、专业概念和符号，听众还没看到问题，就先被抽象信息淹没



反面展示样例

01 为什么要引入GRPO?

1 GRPO 定义

Group Relative Policy Optimization

基于组内相对奖励估计优势的
策略优化方法

2 概率比

$$\rho_i(\theta) = \frac{\pi_{\theta}(o_i | q)}{\pi_{\theta_{\text{old}}}(o_i | q)}$$

符号说明

- q : 输入问题
- o_i : 第 i 个回答
- r_i : 奖励得分
- G : 组内样本数
- ε : 裁剪范围
- β : KL系数

3 组内相对优势

$$\hat{A}_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G)}$$

4 裁剪目标函数

$$J_{\text{GRPO}}(\theta) = \frac{1}{G} \sum_{i=1}^G \min \left[\rho_i \hat{A}_i, \text{clip}(\rho_i, 1-\varepsilon, 1+\varepsilon) \hat{A}_i \right] - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}})$$



问题尚未出现，就直接进入定义、符号和公式推导



推荐展示样例

01 为什么要引入GRPO?

1 案例

用PPO训练大模型




多个模型同时参与训练

2 冲突

价值模型也要单独训练

显存占用高

训练流程复杂




3 追问



4 概念

同一问题采样一组回答



按组内奖励比较相对优劣



这就是GRPO

去掉价值模型，降低训练开销

训练场景

核心矛盾

关键追问

GRPO

先用具体案例建立直觉，再引出专业概念和抽象公式

07 先讲例子，再讲公式



常见问题：在讲解重要概念时，部分讲者直接对着公式推导

反面展示样例

01 强化学习基础公式

1 MDP 定义

$$MDP = (S, A, P, R, \gamma)$$

S : 状态空间

A : 动作空间

$P(s'|s, a)$: 状态转移概率

$R(s, a, s')$: 奖励函数

$\gamma \in [0, 1]$: 折扣因子

2 优化目标

$$\max_{\pi} J(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

$$r_t = R(s_t, a_t, s_{t+1})$$

核心要素

• 状态 s

• 动作 a

• 策略 $\pi(a|s)$

• 价值函数 V, Q

3 Bellman 方程

$$V^{\pi}(s) = \mathbb{E}_{\pi} [r_t + \gamma V^{\pi}(s_{t+1}) | s_t = s]$$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi} [r_t + \gamma Q^{\pi}(s_{t+1}, a_{t+1}) | s_t = s, a_t = a]$$

4 Q-learning 更新

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) +$$

$$\alpha [r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$$


$\alpha \in (0, 1]$: 学习率



推荐展示样例

01 强化学习：迷宫任务与 Q-learning

迷宫任务示例



终点
+10

撞墙
-1

每走一步 -0.1



状态 s : 机器人当前位置



动作 a : 上、下、左、右



奖励 r : 到终点奖励更高



Q-learning 更新公式

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$$

根据交互得到的奖励更新 Q 值。

先用一个具体案例帮助听众理解方法在做什么，然后再展示模型图和公式。

08 用精炼的语言阐述创新点



常见问题：创新点描述过于复杂、陷入实现细节，听众难以快速理解和记忆

反面展示样例

ViT：创新点总结

- **创新点一：** ViT 首先将输入图像划分为固定大小（如 16×16 ）的不重叠图像块（patch），并将每个图像块展平后通过线性映射（Linear Projection）得到低维嵌入向量，形成 Patch Embedding；随后加入可学习的位置编码（Position Embedding）以保留位置信息，并将图像块序列送入 Transformer Encoder。
- **创新点二：** ViT 不依赖传统 CNN 的卷积归纳偏置，而是将图像块序列直接输入标准 Transformer Encoder，通过多头自注意力（Multi-Head Self-Attention）在全局范围内建模不同图像区域之间的依赖关系，并结合前馈网络（MLP）完成特征变换。
- **创新点三：** ViT 先在大规模图像数据集上进行预训练，学习通用视觉表示；随后将预训练模型迁移到下游视觉任务（如图像分类、目标检测、语义分割等）并进行微调（Fine-tuning），提升在具体任务上的泛化性能。



ViT 整体框架（示意）


推荐展示样例

ViT：创新点总结

01 创新点一： 将图像切分为小块，并将其序列化为输入



02 创新点二： 用 Transformer 直接建模图像块之间的全局关系



03 创新点三： 先在大量图片上学习，再迁移到具体任务



精炼创新点，每一个核心贡献用不超过 25 个字的话总结

09 让听众一眼看到重点



常见问题：重要内容的视觉权重相近，听众不知道应该先看哪里



反面展示样例

实验：强化学习奖励设计对训练表现的影响

关键指标汇总（跨 Seed 均值）

指标	Dense	Sparse	Hybrid
平均回报	182.1	141.0	237.9
成功率	84.0%	71.0%	96.0%
收敛回合数	410	470	320
训练时长	1.90 h	1.80 h	2.09 h
AUC	69,963	52,251	90,752
最终回报	200.3	161.9	256.1

实验观察

- Dense: 平均回报 182.1，成功率 84.0%，410 回合收敛。
- Sparse: 平均回报 141.0，成功率 71.0%，470 回合收敛。
- Hybrid: 平均回报 237.9，成功率 96.0%，320 回合收敛。
- 训练时长分别为 1.90 h / 1.80 h / 2.09 h。

最终结论：Hybrid Reward 在大多数关键指标上表现更好。

实验结论

1. Hybrid 平均回报最高 (237.9)。
2. Hybrid 成功率最高 (96.0%)。
3. Hybrid 收敛回合数最少 (320)。
4. Hybrid AUC 最高 (90,752)。
5. Hybrid 最终回报最高 (256.1)。



推荐展示样例

实验：强化学习奖励设计对训练表现的影响

指标	Dense	Sparse	Hybrid
收敛回合数	410	470	320
训练时长	1.90 h	1.80 h	2.09 h
AUC	69,963	52,251	90,752
成功率	84.0%	71.0%	96.0%
平均回报	182.1	141.0	237.9
最终回报	200.3	161.9	256.1

实验结论

1. 收敛回合数最少
(训练时长略长)
2. auc与成功率
大幅提高
3. 平均回报和最终
回报达到最高

最终结论：Hybrid Reward 在 6 项关键指标中的 5 项最优



突出关键数字，标记重要区域，用框线与箭头建立阅读路径——让最重要的信息最先被看到

10 实验部分多用图，少用表格



常见问题：实验页堆满大表格，很难快速看出方法是否有效



反面展示样例

实验结果

Method	GSM8K			MATH-500			AMC23			AIME24			AIME25			AVG.	
	Acc↑	Tok	ReL↓	Acc↑	Tok	ReL↓	Acc↑	Tok	ReL↓	Acc↑	Tok	ReL↓	Acc↑	Tok	ReL↓	Acc↑	ReL↓
Qwen2.5-1.5B Series																	
Ours (Base)	80.1	2086	76.2	78.8	3958	139.4	62.5	6392	242.9	20.0	13765	536.8	16.7	12684	504.7	51.5	300.0
+H2O	76.1	2116	71.7	75.4	3835	128.5	55.0	6230	209.7	13.3	13921	462.2	10.0	12802	428.6	46.0	260.1
+SepLLM	77.3	2230	75.8	76.0	3890	130.3	57.5	6573	220.2	13.3	13690	452.6	13.3	12690	423.9	47.5	260.6
LightThinker	78.8	2109	69.6	77.6	4060	134.8	60.5	6312	214.6	16.7	13827	461.6	13.3	12934	434.6	50.1	263.0
INFTYTHINK	79.5	2503	89.3	78.0	4750	170.2	62.5	7605	263.5	16.7	16318	566.2	16.7	15020	501.0	50.7	318.0
Ours	82.1	2116	69.7	81.2	3812	125.8	67.5	6460	213.2	26.7	13610	440.13	23.3	12910	416.0	56.2	253.0
Qwen2.5-7B Series																	
Ours (Base)	89.4	2649	96.4	87.4	4253	161.6	82.5	6704	242.9	40.0	12901	522.1	30.0	13204	548.1	65.9	314.2
+H2O	83.5	2730	92.0	82.6	4389	147.1	77.5	6843	209.7	30.0	13274	448.9	23.3	13204	443.7	59.4	268.3
+SepLLM	84.9	2582	92.3	84.2	4244	144.3	80.0	6511	220.2	33.3	13100	484.7	23.3	12972	435.9	61.1	275.5
LightThinker	85.6	2779	90.0	84.8	4321	145.2	80.0	6790	214.6	33.3	13307	449.0	26.7	13250	443.9	62.1	268.5
INFTYTHINK	87.9	3237	117.0	86.2	5050	184.8	82.5	8061	254.3	36.7	15094	508.7	30.0	15448	530.5	64.7	319.0
Ours	90.9	2603	87.2	90.0	4196	140.6	85.0	6665	213.2	43.3	13017	434.8	33.3	13191	440.6	68.3	263.3



推荐展示样例

本文方法和baseline的高效性以及准确率实验结果



相比于其他稀疏注意力方法，本方法在准确性提升2-5个点，高效性提升15%左右


准确性

平均准确率 ↑



高效性

平均相对长度 ↓ (低值更优)



优先用图讲趋势，用小表格补充关键数值，不要让观众在大表格中找结论。

11 在总结页回顾核心内容，强化最后印象



常见问题：总结页只有 Thanks，没有提炼核心结论，报告结束后听众记不住重点



反面展示样例

汇报结束！

THANKS

Q & A

感谢聆听！



推荐展示样例

汇报结束！

背景动机



这个框可以图文并茂
整体展示报告的背景
和动机


方法设计

RobotReach-v2
With PPO

Hybrid Reward

这个框可以图文并茂
整体展示报告的方法
设计

实验效果



Hybrid Reward 最好
这个框可以图文并茂
整体展示报告的实验
结果



在总结页回顾报告的关键内容与重要结论，帮助听众带着核心信息离场